PROYECTO · DEMANDA EN TRANSMILENIO

¿Dónde y cuándo reforzar el personal de apoyo?

Validaciones de la troncal por estación y franja horaria · agosto y septiembre de 2026

Universidad de La Sabana

Juan Pablo Sánchez · William Caro · Leidy Simijaca

Curso Big Data · 10 de octubre de 2026

02 · LOS DATOS

Cuáles son nuestros datos y de dónde salen

21
días completos (3 semanas)

154
estaciones de la troncal

31,5 M
validaciones (ingresos con tarjeta)

6
variables relevantes conservadas

Fuente	Contenido	Uso
Validaciones diarias TMSA	Validaciones troncales por día (1 ZIP/CSV por día)	Insumo principal
Estaciones troncales (datos abiertos TM)	Nombre, troncal, latitud y longitud de cada estación	Cruce geoespacial

De millones de transacciones individuales pasamos a una tabla mucho más pequeña: **una fila por estación, fecha y hora**, con su número de validaciones, nombre y tipo de estación.

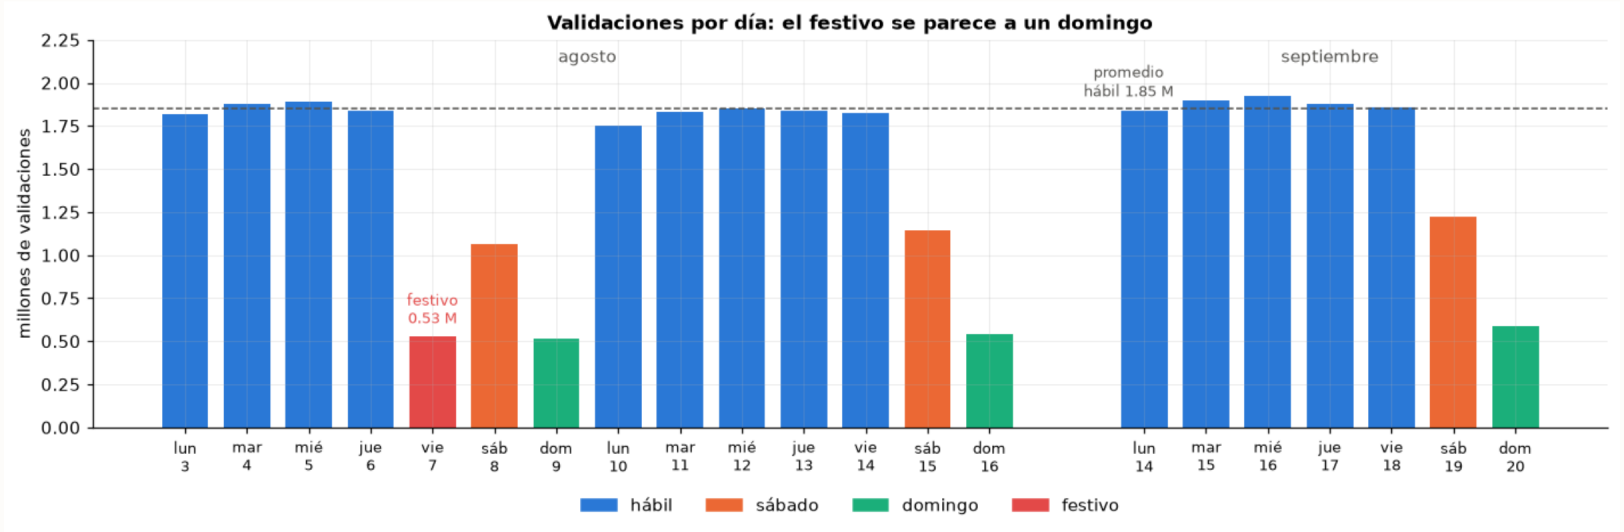
Fuente: validaciones troncales TMSA y datos abiertos de TransMilenio, agosto y septiembre de 2026

03 · PREGUNTA DE ESTUDIO

¿Qué estaciones de la troncal de TransMilenio, y en qué franjas horarias de los días hábiles, concentran la mayor demanda de ingreso y justifican por ello una mayor asignación de personal de apoyo para la gestión de filas y el orden?

04 · QUÉ SE ANALIZÓ

Tres semanas: dos típicas y una con festivo



Semanas típicas

10–16 ago y 14–20 sep, sin festivo: base del análisis

Semana de comparación

3–9 ago, incluye el festivo del 7 de agosto

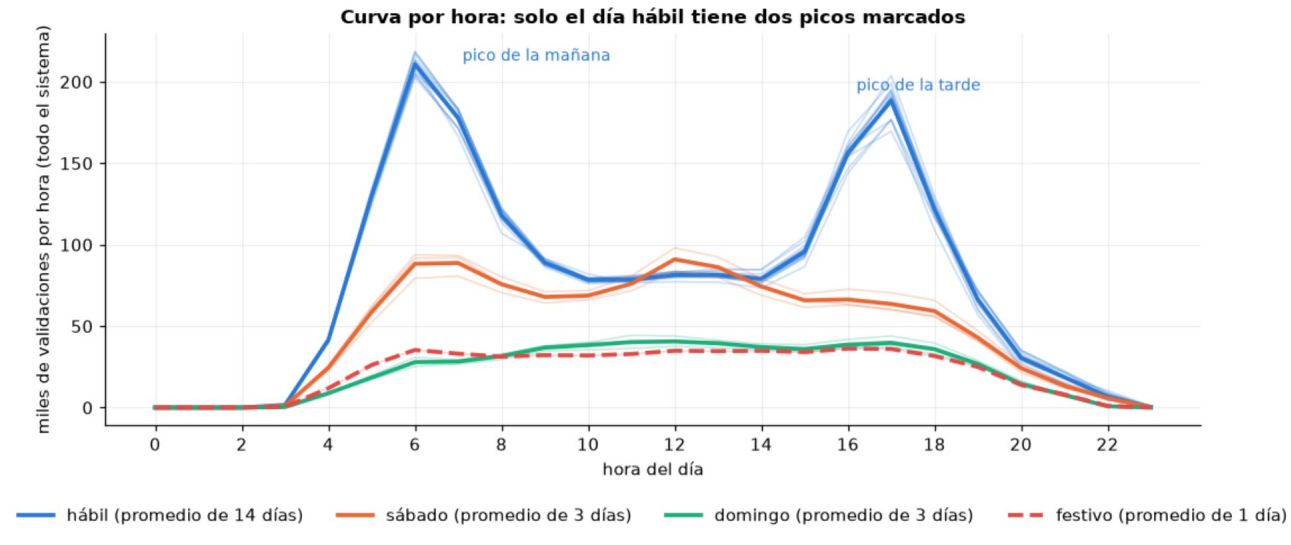
Franjas horarias

Madrugada 4–5 · pico AM 5–9 · mediodía 10–15 · pico PM 16–20 · noche 21–24

Ilustración: validaciones por día (hábil, sábado, domingo y festivo)

05 · DEMANDA A LO LARGO DEL DÍA

Solo el día hábil tiene dos picos marcados



6 a. m.

Pico de la mañana: ~210 mil validaciones por hora en todo el sistema. Llegada concentrada a trabajo y estudio.

5 p. m.

Pico de la tarde: ~188 mil, más bajo y repartido en más horas: el regreso es más flexible.

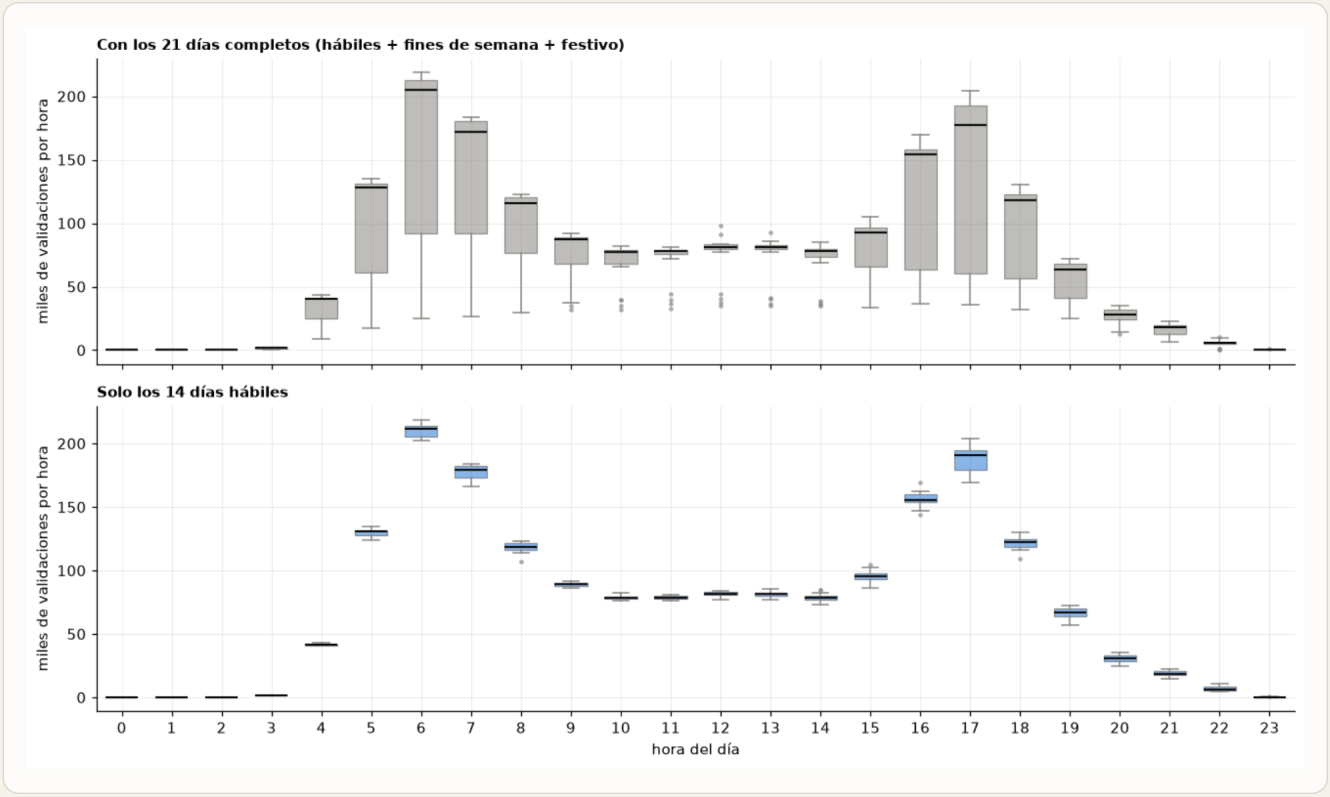
Fin de semana

Sábado ≈ 58 % y domingo ≈ 28 % de un hábil, sin picos.

Ilustración: demanda por hora según el tipo de día

06 · DECISIÓN SOBRE LA MUESTRA

Solo días hábiles: un patrón muy estable



Con los 21 días

Las cajas son muy anchas: mezclar hábiles, fines de semana y festivo esconde el patrón.

Solo los 14 hábiles

Las cajas casi se cierran: cada hora se repite de un día a otro.

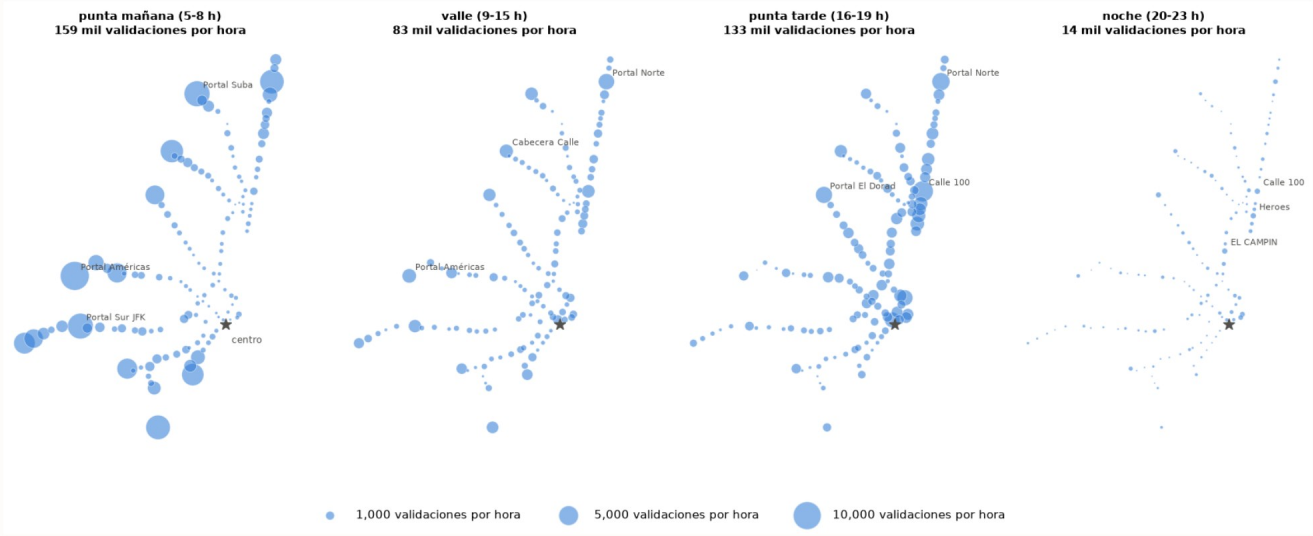
Decisión

El festivo se comporta como un domingo: se excluye y el análisis de refuerzo usa días hábiles.

Ilustración: boxplot de validaciones por hora, todos los días frente a solo hábiles

07 · DÓNDE ESTÁ LA DEMANDA

La demanda se mueve por la ciudad



Mañana: nace en los portales

Portales y cabeceras de zonas residenciales: Américas, Sur, Suba, Usme

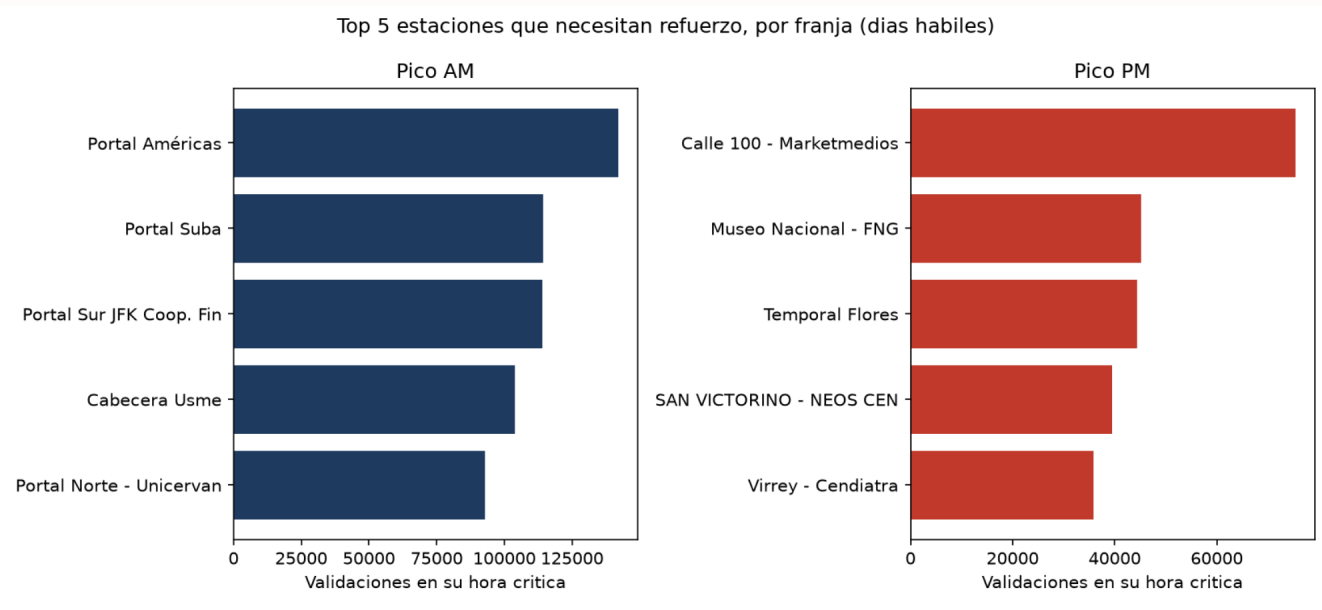
Tarde: sale de oficinas y comercio

Corredor norte y centro: Calle 100, Calle 76, Héroes, San Victorino

Ilustración: mapa de calor de la demanda por franja (tamaño = validaciones por hora)

08 · RANKING DE REFUERZO

Estaciones que más necesitan refuerzo



Pico AM: portales

Puntos donde se concentra la gente que sale de zonas residenciales.

Pico PM: destinos

Estaciones rodeadas de oficinas y comercio.

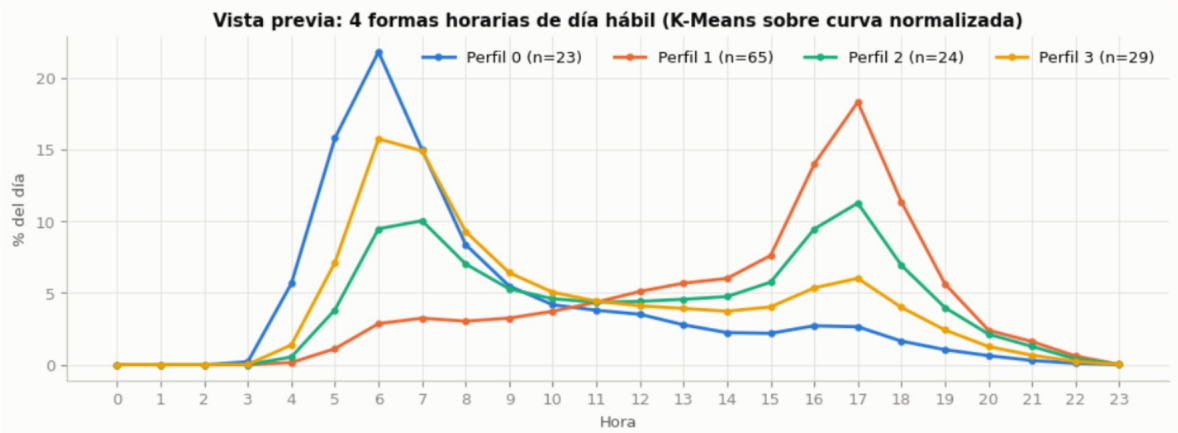
5 % → 39 %

El 5 % de las combinaciones estación–hora concentra el 39 % de las validaciones de un día hábil.

Ilustración: ranking de estaciones por franja (días hábiles)

09 · PERFILES DE ESTACIONES (K-MEANS)

Cuatro formas de vivir el día hábil



Residencial AM fuerte
Perfil 0 · 23 est. · 66 % en pico AM · Portal Américas, Sur, Suba

Residencial moderado
Perfil 3 · 29 est. · 53 % AM · Portal Norte, Calle 80, Banderas

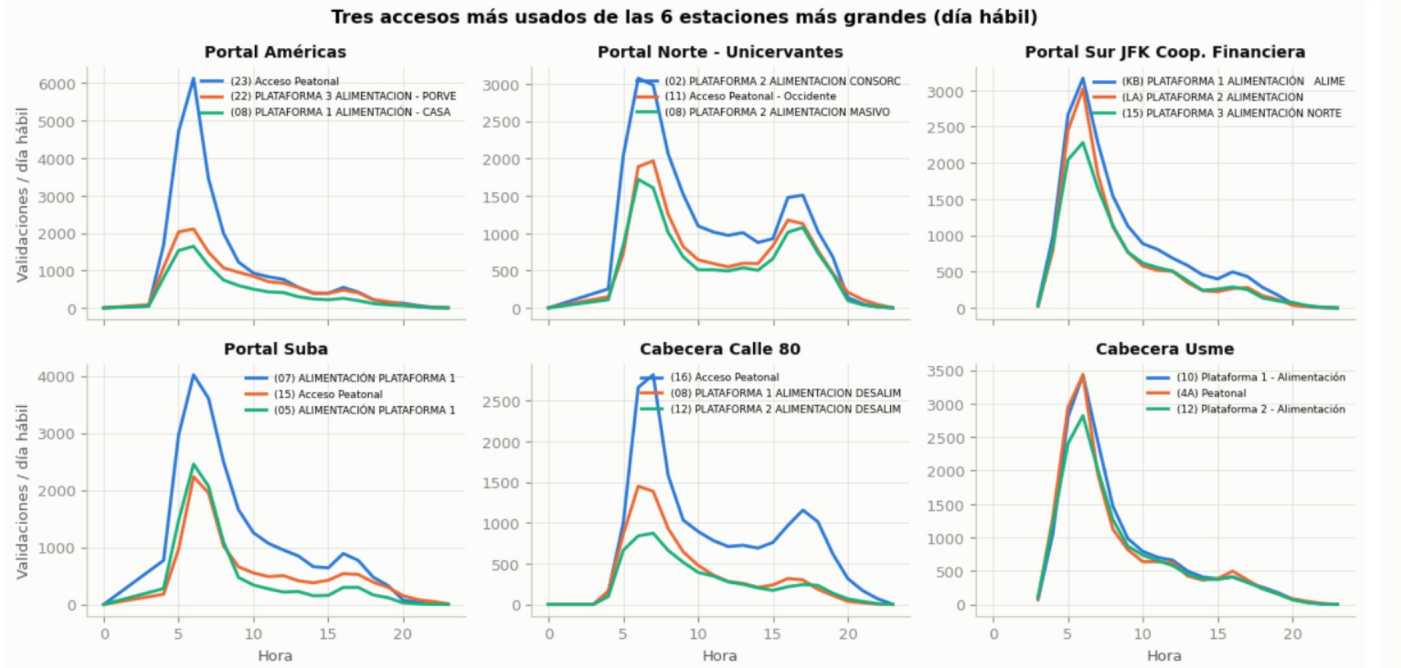
Mixto / transbordo
Perfil 2 · 24 est. · AM ≈ PM · Portal El Dorado, Alcalá, Restrepo

Destino / salida PM
Perfil 1 · 65 est. · 52 % PM · Calle 100, Calle 76, Flores

Ilustración: K-Means sobre la curva horaria normalizada (forma del día, sin volumen)

10 · ACCESOS EN PORTALES

Reforzar el acceso, no solo la estación



51–75 %

de las validaciones de los portales entra por **plataformas de alimentación**, no por el acceso peatonal.

El apoyo debe repartirse donde se controla el flujo de entrada.

Ilustración: tres accesos más usados de las seis estaciones más grandes (día hábil)

11 · MODELO

¿El histórico reciente permite anticipar mañana?

Lo que ya tenemos

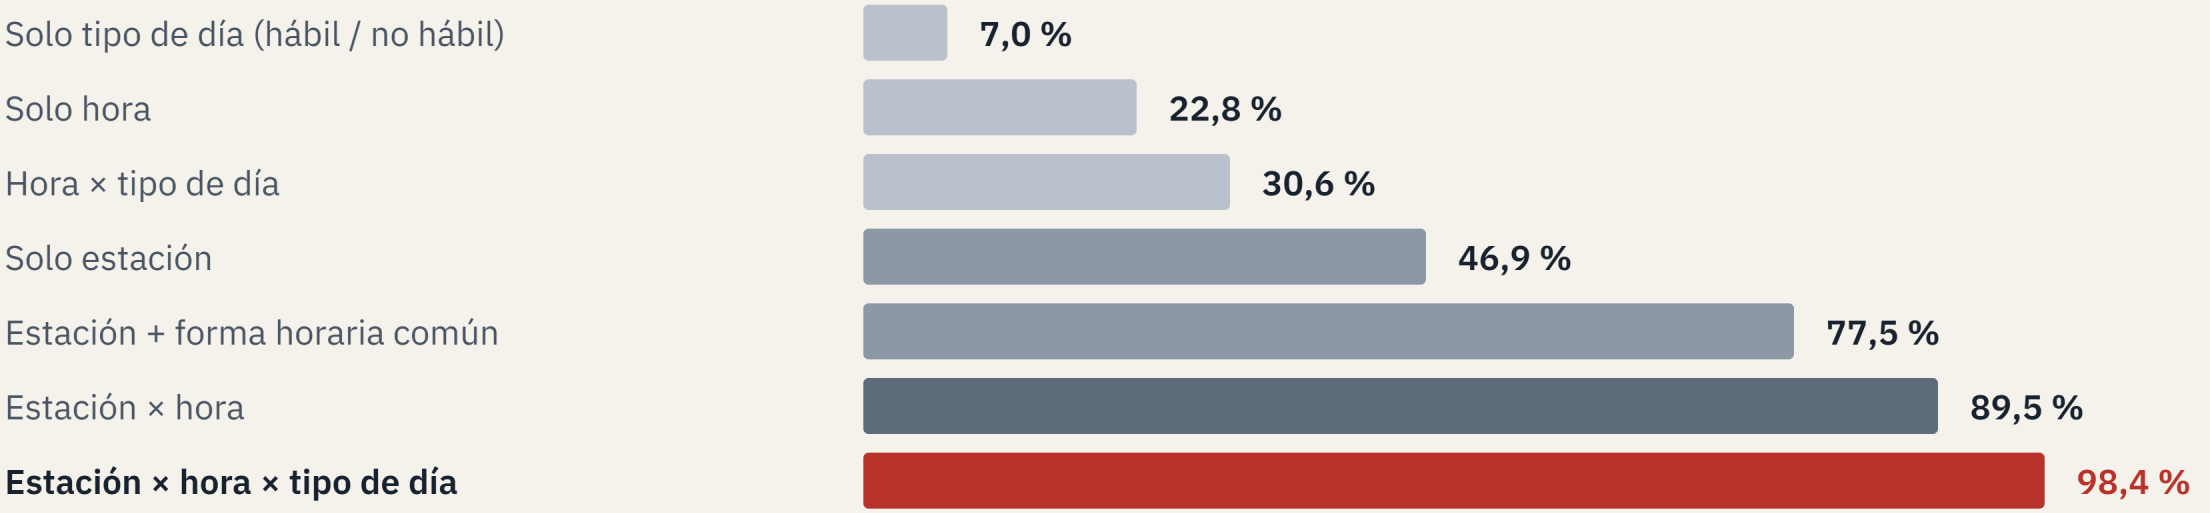
El ranking dice dónde y cuándo **hubo** presión.

Lo que necesita el operador

Saber dónde y cuándo **habrá** presión, con anticipación y un error conocido, para programar turnos.

12 · POR QUÉ SE PUEDE PREDECIR

Estación × hora × tipo de día lo explica casi todo



Cada barra = qué parte de la demanda se explica sabiendo solo eso. Conociendo estación, hora y tipo de día ya se explica el **98 %**; y de un día hábil a otro cada estación cambia apenas **3,5 %**.

Medida: % de devianza de Poisson explicada (similar al R^2 para datos de conteo) · Prueba con 11 días (3–13 ago 2026)

13 · CÓMO LO EVALUAMOS

Entrenar con el pasado, medir en días futuros

Entrenamiento · 3 al 10 de agosto (8 fechas)
El modelo solo ve estos días

Prueba · 11–13 ago
3 días hábiles nuevos

Método	Cómo predice cada estación y hora
Ayer	Misma hora del día anterior
Hace 7 días	Misma hora, mismo día de la semana pasada
Último comparable	Último día del mismo tipo (hábil / sáb / dom)
Promedio comparable	Promedio de los días anteriores del mismo tipo
ML (Gradient Boosting)	Aprende de hora, día, estación e historia

Métrica: WAPE

Error absoluto total ÷ validaciones reales. Un WAPE de 6 % significa que el error suma 6 de cada 100 validaciones.

Sin “trampa”: cada predicción usa solo datos anteriores al día pronosticado.

Prueba de concepto con 11 días (3–13 ago 2026)

El promedio de días comparables gana

Método	WAPE día	WAPE pico	MAE
Ayer	7,0 %	6,5 %	42,9
Hace 7 días	8,2 %	7,4 %	50,1
Último comparable	7,0 %	6,5 %	42,9
Promedio comparable (mejor)	6,0 %	5,4 %	36,6
ML · Gradient Boosting Poisson	7,8 %	7,7 %	47,7

6,0 %

de error al anticipar el día siguiente (5,4 % en hora pico)

El ML queda con **30 % más error** que la referencia sencilla.

MAE = error absoluto medio en validaciones por hora · Prueba en 11, 12 y 13 de agosto

15 · EJEMPLO: PORTAL AMÉRICAS

Pronóstico y realidad casi se superponen



La forma del día ya se conoce; el reto está en las **desviaciones puntuales** del pico, donde se juega el refuerzo.

Ilustración: pronóstico hora a hora en las fechas de prueba (4–23 h)

16 · JUSTIFICACIÓN DEL MODELO

Por qué elegimos el modelo más simple

1. Es el más preciso

El promedio de días comparables anticipa mañana con 6 % de error (5,4 % en pico). Ningún otro método lo superó.

2. Es lo que los datos indican

Estación × hora × tipo de día explica el 98 % y los hábiles varían ~3,5 %: el pasado es la mejor guía.

3. El ML aún no se justifica

Solo 8 fechas de entrenamiento (5 con historia previa). Su variable más importante es… el mismo promedio.

4. Es fácil de explicar y operar

Cualquier supervisor lo entiende y lo calcula, y queda como la vara que un ML futuro debe superar.

Siguiente paso: con más semanas y datos de eventos, obras y clima, el ML podría corregir donde el promedio falla (Av. Jiménez temporal, Calle 40 Sur, CAD, El Campín, Corferias).

Respuesta a la pregunta de estudio

Dónde	Mañana: portales (Américas, Suba, Sur, Usme) y sus plataformas de alimentación. Tarde: Calle 100, Museo Nacional, Flores, San Victorino.
Cuándo	5–8 a. m. y 4–7 p. m. de días hábiles: el 5 % de las combinaciones estación–hora reúne el 39 % de la demanda.
Cómo planear	Con el promedio de días comparables se anticipa el día siguiente con ~6 % de error.
Límite	Los datos dicen dónde y cuándo, no cuántas personas: falta la capacidad de las estaciones y los tiempos de fila.